

指令配对数据 JSONL
data/sft_train.jsonl
每行: {"instruction": "...", "output": "..."}
↓

format_example()
prompt = "用户:{instruction}\n助手:"
target = "{output}\n"
→ (prompt_str, target_str)
↓

分别编码
p_ids = tokenizer.encode(prompt) # 不算 loss
t_ids = tokenizer.encode(target) + [EOS] # 算 loss
↓

构造 Loss Mask (核心差异)
labels = [-100] * len(p_ids) + t_ids
input_ids = p_ids + t_ids
-100 = ignore_index (PyTorch/HF 惯例)
↓

SFTDataset 预编码所有样本
存储 (input_ids, labels) 列表
random_batch() 时 pad 到统一长度
input pad=0, label pad=-100
↓

model(x[:, :-1]) # 去掉最后一个 token
logits [B, S, V]
↓

对比: 预训练 vs SFT

项目	预训练	SFT
数据格式	连续文本流	配对指令数据
标签构造	$y = x \gg 1$	prompt=-100
学习目标	建模语言分布	学会遵循指令
学习率	3e-4	3e-5 ~ 6e-5
训练单位	steps	epochs
权重初始化	随机	预训练热启动

F.cross_entropy(..., ignore_index=-100)
仅 answer 部分 (labels != -100) 产生梯度
prompt 部分梯度为 0
防止灾难性遗忘·模仿问句写法
↓

SFT 训练循环
热启动: load_model(预训练 ckpt)
lr = 3e-5 ~ 6e-5 (预训练 1/5~1/10)
1-3 epochs, cosine decay
梯度累积 + 裁剪 + 保存