


Input Tokens
[Batch, Seq_Len]
int64 token IDs

Token Embedding
nn.Embedding(V, D)
→ [B, S, D]
↑ 权重共享 ↑
Weight Tying
(Press & Wolf 2017)

N × TransformerBlock
(Pre-Norm 残差结构)
L = num_layers (默认 8)



Final RMSNorm
归一化收尾
→ [B, S, D]

LM Head (输出投影)
nn.Linear(D, V, bias=False)
→ logits [B, S, V]
权重 = tok_embeddings.weight (共享)

Logit Soft Cap (Gemma 风格)
logits = 50 * tanh(logits / 50)
防止个别维度发散 · 破坏 bf16 训练

Output Logits
[Batch, Seq_Len, Vocab_Size]
float32 (softmax/CE 数值稳定)

- 核心组件详解:
- RMSNorm: LayerNorm 简化版
 $y = x / \sqrt{\text{mean}(x^2) + \text{eps}} * \gamma$
无减均值 · 无 bias, 更快更稳
 - RoPE 旋转位置编码
相邻二维看作 2D 向量, 按位置旋转
 $q \cdot k$ 内积只依赖相对距离
支持外推到更长序列
 - GQA (Grouped Query Attention)
Q: H 头, K/V: H_{kv} 头 ($H_{kv} < H$)
 $n_{rep} = H / H_{kv}$ 次复制 KV
推理 KV Cache 显存降 n_{rep} 倍
 - SwiGLU FFN
 $\text{down}(\text{silu}(\text{gate}(x)) * \text{up}(x))$
门控机制, 中间维 $\approx 8/3 * D$
 - KV Cache 增量解码
Prefill 填充, Decode 只算新 token
 $\text{cat}([\text{cache}, \text{new}], \text{dim}=2)$ 拼接
显式因果掩码保证正确性